

EDA 및 모델링 1

⚙ Status	Not started
👤 Assign	🐼 남건우

Segment

A	162	0.04
B	24	0.01
C	21265	5.32
D	58207	14.55
E	320342	80.09

극심한 클래스 불균형 → macro-f1 사용?

모델 - 트리 계열(LightGBM/CatBoost)가 클래스 불균형에 유리

8개 테이블은 모두 1대1 관계. Left join으로 해결.

[baseline_summary.md](#)

[eda_summary.md](#)

[fe_summary.md](#)

[model_cascade_summary.md](#)

베이스라인까지 만들어서 돌려본 상태. macro f1 성능

구분	Tier1+2 피쳐 (31개)	전체 피쳐 (175개)
OOF Macro-F1	0.4512	0.4809
A (162명)	0.215	0.199
B (24명)	0.000	0.000
C	0.579	0.658
D	0.554	0.619
E	0.908	0.928

B를 하나도 못 잡아냄 → B 저격/특화 파생변수 생성 필요성

B에 대한 해결책

1. B 잘 잡아낼 수 있는 파생변수 생성
2. cascade - 세그먼트(등급) 예측을 할때
E와 non-E 분류 → (A or B) 와 non-(A or B) 분류 → A와 B 중 B 탐지
 - a. 클래스 불균형에 대처하기 위함

v1 cascade 결과

구분	v0 베이스라인	v1 Cascade	변화
Macro-F1	0.4809	0.8467	+0.366
B F1	0.000	0.680	탈출 성공
A F1	0.199	0.950	
E F1	0.928	1.000	

B 24명 중 17명(71%) 포착. 나머지 7명은 A로 오분류 — B와 A가 피쳐 공간에서 매우 가깝다는 의미.

제출 결과

데이콘에 v1 cascade 제출 결과 0.47649라는 형편없는 점수를 받음... 과적합?

baseline이 0.48287으로 베이스라인보다 못한 성능을 보여줌

데이터 누수를 조심하자!

데이터 누수를 해결했음에도 v2 cascade 0.44 ... → 이걸 옳은 방식이 아니다