

eda

Status	Not started
Assign	배순은

구조 확인1) train/test에 고객이 몇 명 있는지 확인

각 월마다 1.회원정보 테이블에서 ID 만 읽고,
행 수, 고유 고객 수, 중복 ID 수를 확인함.

코드에서는 `train`, `test` 를 돌고, 각 월별로 `ID` 만 읽어서 `행수`, `고유고객수`, `중복ID수` 를 계산

train은 매월 고객 40만 명짜리 데이터

test는 매월 고객 10만 명짜리 데이터

그리고 같은 월 안에서 ID 중복은 없음

→ 한 고객이 한 달에 한 줄씩만 있다

2) 1~8번 테이블도 같은 고객 수인지 확인

2018년 12월 기준으로 1번부터 8번 테이블을 봄

왜 201812를 봤냐면, 보통 가장 최신 월이 예측에 가장 중요하기 때문

201812 기준으로

1번 테이블에도 고객이 40만 명인지,

2번 테이블에도 고객이 40만 명인지,

...

8번 테이블에도 고객이 40만 명인지 확인.

▼ 코드에서도 `train`, `test` 각각에 대해 1번부터 8번 테이블까지 ID 만 읽고, `행수`, `고유고객수`, `중복ID수` 를 저장합니다.

결과

구분	테이블	월	행수	고유 고객 수	중복 ID 수
train	1.회원정보	201812	400,000	400,000	0
train	2.신용정보	201812	400,000	400,000	0
train	3.승인매출정보	201812	400,000	400,000	0
train	4.청구입금정보	201812	400,000	400,000	0
train	5.잔액정보	201812	400,000	400,000	0
train	6.채널정보	201812	400,000	400,000	0
train	7.마케팅정보	201812	400,000	400,000	0
train	8.성과정보	201812	400,000	400,000	0
test	1~8번 전체	201812	100,000	100,000	0

저장된 `02_latest_month_join_summary.csv` 에도 201812 기준 train의 1~8번 테이블은 모두 400,000행, test의 1~8번 테이블은 모두 100,000행

3) 월별 고객 겹침 확인: 같은 고객 40만 명을 6개월 동안 관찰한 구조

201807에 있던 고객 40만 명이

201808에도 그대로 있나?

201809에도 그대로 있나?

201812까지 계속 같은 고객인가?

결과

이전월	다음월	겹치는 고객 수	겹침 비율
201807	201808	400,000	1.0
201808	201809	400,000	1.0
201809	201810	400,000	1.0
201810	201811	400,000	1.0
201811	201812	400,000	1.0

4) Segment 안정성 확인

같은 고객의 Segment가 7월에는 E, 8월에는 D, 9월에는 C처럼 바뀌나?

아니면 6개월 내내 같은 Segment인가?

train 고객 40만 명 전부가

6개월 동안 Segment가 바뀌지 않았습니다.

▼ 예

ID	201807 Segment	201808 Segment	201809 Segment	...	201812 Segment
고객001	E	E	E	...	E
고객002	D	D	D	...	D
고객003	C	C	C	...	C

아무튼

이 데이터는:

고객 1명이 한 행이고, 고객의 정보가 8개 테이블에 나뉘어 있으며, 6개월치가 월별로 저장되어 있는 고객 Segment 분류용 데이터입니다.

그리고 지금 “데이터 구조 확인”에서 한 일은:

각 월/각 테이블에 고객이 몇 명 있는지, ID가 중복되지 않는지, 월별로 같은 고객인지, Segment가 바뀌지 않는지를 확인한 것입니다.

진짜 핵심만 외우면 이겁니다.

ID = 고객
행 = 고객 한 명
컬럼 = 고객 특징
1~8번 테이블 = 고객 특징 묶음
201807~201812 = 6개월 관찰
Segment = 맞춰야 하는 정답
train = 정답 있는 데이터
test = 정답 예측할 데이터

3차원 구조로 보면 됩니다.

고객 ID
x
월 6개
x
테이블 8개

조금 더 풀면:

고객001
├─ 201807
│ ├── 회원정보
│ ├── 신용정보
│ └── 승인대출정보
│ └── ...
└─ 201808

A Segment는 40~50대 비중이 높고, 성별코드 1 쪽으로 치우쳐 있으며, 평균 유효 신용카드 수가 가장 많습니다.
E Segment는 성별 비율이 거의 반반이고, 20대 비중이 상대적으로 높으며, 평균 유효 신용카드 수가 가장 적습니다.
B는 연체율과 마케팅동의율이 높아 보이지만, 고객 수가 24명뿐이라 해석을 조심해야 합니다.

그래서 이 EDA에서 얻은 핵심은:

Segment별로 연령, 성별, 카드 보유 수 차이가 존재한다. 특히 카드 보유 수는 A와 E를 구분하는 데 꽤 도움이 될 가능성

1) 연령

Segment A/B/C/D/E 고객들은

나이, 성별, 연체율, 마케팅동의율, 보유 카드 수가 다를까

1번 회원정보 테이블만 사용했습니다.

사용한 컬럼은:

컬럼	의미
Segment	고객 그룹
연령	연령대
남녀구분코드	성별 코드
회원여부_연체	연체 여부
마케팅동의여부	마케팅 동의 여부
소지카드수_유효_신용	보유 중인 유효 신용카드 수

Segment	20대	30대	40대	50대	60대	70대 이상
A	0.62%	8.02%	37.04%	38.89%	11.11%	4.32%
B	4.17%	29.17%	33.33%	33.33%	0.00%	0.00%
C	3.24%	25.28%	37.93%	23.26%	7.75%	2.54%
D	7.44%	29.28%	33.16%	20.28%	7.65%	2.20%
E	8.42%	23.80%	29.58%	23.17%	10.94%	4.09%

A Segment는 40대, 50대 비중이 매우 큼니다.

A의 40대는 37.04%, 50대는 38.89%입니다. 합치면 약 75.93%입니다.

즉 A는:

40~50대 중심 Segment

라고 볼 수 있습니다.

반대로 E Segment는 다른 Segment보다 20대 비중이 상대적으로 높습니다.

E의 20대 비중은 8.42%입니다. A는 0.62%, C는 3.24%라서 E가 더 젊은 쪽 비중이 높습니다.

다만 E도 40대, 50대가 많긴 합니다.

그래서 “E는 젊은 고객만 있다”는 뜻은 아닙니다.

정리하면:

A는 40~50대가 강하게 많고,
C/D도 30~40대 중심이며,
E는 상대적으로 20대 비중이 더 높습니다.

2. 성별 비율 결과

Segment	성별코드 1	성별코드 2
A	70.99%	29.01%
B	54.17%	45.83%
C	61.47%	38.53%
D	56.76%	43.24%
E	50.88%	49.12%

A Segment는 성별코드 1 비중이 매우 높습니다.

A는 성별코드 1이 70.99%입니다.

반대로 **E Segment는 거의 5:5에 가깝습니다.**

E는 성별코드 1이 50.88%, 성별코드 2가 49.12%입니다.

정리하면:

A는 특정 성별코드 쪽으로 많이 치우쳐 있고,
E는 성별 비율이 거의 반반입니다.

3. 연체율 결과

Segment	연체율
A	1.23%
B	4.17%
C	2.22%
D	2.49%
E	1.46%

해석

B Segment의 연체율이 가장 높습니다.

B는 4.17%입니다.

그다음은 D 2.49%, C 2.22%, E 1.46%, A 1.23% 순서입니다.

다만 주의할 점이 있습니다.

B Segment는 고객 수가 24명밖에 없습니다. 그래서 B의 4.17%는 실제로는 **24명 중 1명 정도**의 영향일 가능성이 큼니다.

정리하면:

숫자만 보면 B의 연체율이 가장 높지만,

| B는 표본 수가 너무 작아서 해석을 조심

4. 마케팅동의율 결과

Segment	마케팅동의율
A	75.31%
B	87.50%
C	75.47%
D	77.72%
E	81.83%

해석

B와 E의 마케팅동의율이 높습니다.

B는 87.50%, E는 81.83%입니다.

다만 B는 고객 수가 너무 적으므로 조심해야 합니다.

실질적으로 많이 봐야 하는 건 C, D, E인데,

그중에서는 **E가 마케팅동의율이 가장 높습니다.**

정리하면:

| E Segment는 카드 사용량은 낮은 편이지만, 마케팅동의율은 상대적으로 높습니다.

5. 평균 유효 신용카드 수 결과

Segment	평균 유효 신용카드 수
A	2.1790장
B	1.8750장
C	1.8335장
D	1.5479장
E	1.1461장

해석

이 결과가 꽤 중요합니다.

Segment가 A → B/C → D → E로 갈수록 평균 보유 카드 수가 줄어드는 흐름이 보입니다.

Segment	해석
A	평균 약 2.18장, 가장 많음
C	평균 약 1.83장
D	평균 약 1.55장
E	평균 약 1.15장, 가장 적음

즉:

| A 고객은 신용카드를 여러 장 보유한 고객이 많고,

E 고객은 신용카드 보유 수가 적은 고객이 많습니다.

이건 Segment 예측에 꽤 도움이 될 수 있는 변수로 보입니다.

3. 소비 / 신용 행동 EDA

Segment별로 카드 한도, 이용 건수, 이용 금액, 청구 금액, 잔액, 혜택 수혜율이 다를까?

(Segment를 구분하는 데 소비/신용 행동이 도움이 될지 확인)

A/B는 카드 사용량, 청구금액, 잔액이 크고

E는 카드 사용량이 매우 작음.

그래서 소비/신용 행동 변수들은 Segment 예측에 중요할 가능성

테이블	사용한 컬럼
1.회원정보	ID, Segment
2.신용정보	카드이용한도금액
3.승인매출정보	이용건수_신용_B0M, 이용금액_일시불_B0M
4.청구입금정보	청구금액_B0
5.잔액정보	잔액_일시불_B0M
8.성과정보	혜택수혜율_B0M

이 테이블들을 각각 읽은 다음 ID 기준으로 합치고, Segment별 중앙값을 계산

(평균이 아니라 중앙값을 쓴 이유는, 돈 관련 데이터는 아주 큰 값이 튀는 경우가 많기 때문)

Segment	카드이용한도금액	신용 이용건수	일시불 이용금액	청구금액	일시불 잔액	혜택수혜율
A	200,964.5	62.0	22,571.0	44,690.5	18,443.0	1.57
B	90,758.0	57.5	20,339.5	41,744.5	19,817.5	1.53
C	86,526.0	35.0	11,226.0	17,345.0	7,644.0	1.47
D	52,437.0	24.0	6,385.0	8,528.0	4,440.0	1.52
E	40,478.0	3.0	1,307.0	1,373.0	732.0	0.58

A Segment가 전반적으로 가장 활동성이 큼니다.

A는 카드이용한도금액 중앙값이 200,964.5로 가장 높고, 신용 이용건수도 62.0으로 가장 높습니다. 일시불 이용금액도 22,571.0, 청구금액도 44,690.5로 큼니다.

E Segment는 거의 모든 소비/신용 지표가 가장 낮습니다.

E는 신용 이용건수 중앙값이 3.0입니다. A가 62.0인 것과 비교하면 차이가 매우 큼니다. 일시불 이용금액도 E는 1,307.0, A는 22,571.0입니다.

즉 실제 결과를 한 줄로 쓰면:

A/B는 카드 사용량과 청구금액이 큰 Segment이고, E는 카드 사용량·이용금액·청구금액이 매우 낮은 Segment입니다.

특히 `이용건수_신용_B0M`, `이용금액_일시불_B0M`, `청구금액_B0` 는 Segment를 구분하는 데 중요

4. 월별 변화 EDA

Segment별 소비 수준 차이가 한 달짜리 우연인지, 6개월 동안 꾸준한 특징인지 확인

(한 달만 보지 않고, 201807부터 201812까지 6개월 변화)

Segment별 소비 패턴이 6개월 동안 비슷하게 유지되는가?

아니면 특정 월에 크게 바뀌는가?

결과

월별 변화에서 중요한 건 “한 달만 우연히 그런가?”를 보는 겁니다.

실제 숫자를 보면 201807부터 201812까지 계속 비슷한 패턴입니다.

정리하면:

지표	실제 패턴
신용 이용건수	A/B 높음, E 매우 낮음
일시불 이용금액	A/B 높음, C 중간, D 낮음, E 매우 낮음
청구금액	A/B 높음, C 중간, D 낮음, E 매우 낮음

그래서 결론은:

■ 소비/신용 행동 차이는 201812 한 달만의 현상이 아니라, 6개월 동안 반복적으로 유지되는 Segment 특징

—

테이블	사용한 컬럼
1.회원정보	<code>ID</code> , <code>Segment</code>
3.승인매출정보	<code>이용건수_신용_B0M</code> , <code>이용금액_일시불_B0M</code>
4.청구입금정보	<code>청구금액_B0</code>

6개월을 하나씩 돌면서, 월마다 위 컬럼들을 ID 기준으로 합치고, Segment별 중앙값을 계산

15_monthly_trends.png

4-1. 월별 신용 이용건수 중앙값

기준년월	A	B	C	D	E
201807	60.0	64.5	37.0	27.0	5.0
201808	60.5	64.0	37.0	26.0	4.0
201809	59.0	63.0	36.0	25.0	4.0
201810	60.5	63.5	36.0	25.0	3.0
201811	61.0	61.5	36.0	24.0	3.0
201812	62.0	57.5	35.0	24.0	3.0

해석

신용 이용건수는 **A와 B가 높고, E가 매우 낮습니다.**

A는 6개월 동안 **59.0~62.0** 수준입니다.

B도 **57.5~64.5** 수준입니다.

반면 E는 **3.0~5.0** 수준입니다.

즉:

E Segment는 6개월 내내 신용카드 이용건수가 매우 낮습니다.

A/B Segment는 6개월 내내 이용건수가 높습니다.

4-2. 월별 일시불 이용금액 중앙값

기준년월	A	B	C	D	E
201807	22,651.0	22,426.0	11,631.0	7,028.0	1,556.0
201808	22,045.5	22,080.5	11,481.0	6,877.0	1,537.0
201809	22,715.0	21,132.0	11,431.0	6,696.0	1,486.0
201810	22,673.0	21,295.0	11,306.0	6,584.0	1,419.0
201811	22,619.0	22,342.5	11,183.0	6,434.0	1,352.0
201812	22,571.0	20,339.5	11,226.0	6,385.0	1,307.0

해석

일시불 이용금액도 **A/B가 높고, E가 낮습니다.**

A는 6개월 내내 약 **22,000** 대입니다.

B도 대부분 **20,000~22,000** 대입니다.

C는 **11,000** 대, D는 **6,000** 대, E는 **1,300~1,500** 대입니다.

즉 소비금액 기준으로 보면:

A/B > C > D > E 순서가 매우 뚜렷합니다.

이건 꽤 중요한 결과입니다. Segment가 단순히 이름만 다른 게 아니라, 실제 카드 사용금액 차이가 크게 납니다.

4-3. 월별 청구금액 중앙값

기준년월	A	B	C	D	E
201807	44,980.5	39,267.0	17,074.0	8,864.0	1,395.0
201808	44,043.0	43,330.5	17,055.0	8,843.0	1,473.0
201809	45,545.0	41,078.0	17,646.0	9,003.0	1,482.0
201810	45,716.5	45,940.5	17,570.0	8,867.0	1,462.0
201811	45,555.5	46,936.0	17,402.0	8,761.0	1,429.0
201812	44,690.5	41,744.5	17,345.0	8,528.0	1,373.0

해석

청구금액도 A/B가 압도적으로 높고, E가 매우 낮습니다.

A는 6개월 내내 44,000~45,000 대입니다.

B도 39,000~46,000 대입니다.

C는 17,000 대, D는 8,000~9,000 대, E는 1,300~1,400 대입니다.

즉:

월별로 봐도 Segment 간 소비 수준 차이는 일관됩니다.

특히 A/B는 청구금액이 높고, E는 청구금액이 낮습니다.

5) 결측치 EDA결론

결측치 결과에서 실제로 말할 수 있는 결론은 이겁니다.

201812 train 기준으로, 일부 컬럼은 결측치가 너무 많습니다. 특히 연체일자_BOM, 승인매출정보의 순위 업종 컬럼들, 카드론 관련 컬럼들은 결측 비율이 매우 높습니다.

모델링할 때는 이런 컬럼을 그냥 넣으면 안 됩니다.

처리 방향은 보통 둘 중 하나입니다.

처리 방법	언제 쓰는가
컬럼 제거	결측이 너무 많아서 정보가 거의 없다고 판단될 때
결측 여부 자체를 변수화	비어 있다는 사실 자체가 의미 있다고 볼 때

예를 들어 연체일자_BOM 이 비어 있다는 것은 “연체가 없어서 날짜가 없는 것”일 수도 있습니다.

이 경우 단순히 “결측치라서 버림”이 아니라, 연체일자 존재 여부로 바꾸면 의미가 생길 수도 있습

순위	테이블	컬럼	결측 비율
1	5.잔액정보	연체일자_BOM	0.9990
2	3.승인매출정보	_3순위여유업종	0.9974
3	3.승인매출정보	_2순위여유업종	0.9846
4	3.승인매출정보	_3순위납부업종	0.9638
5	3.승인매출정보	_1순위여유업종	0.8961
6	3.승인매출정보	_3순위교통업종	0.8629
7	3.승인매출정보	_2순위납부업종	0.8539
8	3.승인매출정보	최종카드론_대출일자	0.8285
9	3.승인매출정보	최종카드론_신청경로코드	0.8155
10	3.승인매출정보	최종카드론_금융상환방식코드	0.8154
11	2.신용정보	RV신청일자	0.8141
12	3.승인매출정보	_2순위교통업종	0.7018
13	6.채널정보	OS구분코드	0.6807
14	1.회원정보	_2순위신용체크구분	0.4043
15	8.성과정보	혜택수혜율_BOM	0.2361

순위	테이블	컬럼	결측 비율
16	1.회원정보	최종유효년월_신용_이용	0.2334
17	8.성과정보	혜택수혜율_R3M	0.2158
18	1.회원정보	가입통신회사코드	0.1557
19	1.회원정보	직장시도명	0.1042
20	1.회원정보	최종유효년월_신용_이용가능	0.0944

해석

가장 심한 결측은 5.잔액정보 의 연체일자_BOM 입니다.

결측 비율이 0.9990 입니다.

즉, 99.90%가 비어 있습니다.

201812 train 고객 수가 400,000명이므로, 대략 계산하면:

컬럼	결측 비율	대략 비어 있는 고객 수
연체일자_BOM	0.9990	약 399,600명

이 컬럼은 거의 대부분 비어 있으므로, 일반적인 숫자 변수처럼 그대로 쓰기 어렵습니다.

결측치가 특히 많은 테이블

상위 20개를 보면, 결측치가 많은 컬럼이 특히 3.승인매출정보에 몰려 있습니다.

3.승인매출정보에서 결측이 큰 컬럼

컬럼	결측 비율
_3순위여유업종	0.9974
_2순위여유업종	0.9846
_3순위납부업종	0.9638
_1순위여유업종	0.8961
_3순위교통업종	0.8629
_2순위납부업종	0.8539
최종카드론_대출일자	0.8285
최종카드론_신청경로코드	0.8155
최종카드론_금융상환방식코드	0.8154
_2순위교통업종	0.7018

승인매출정보 안에서도 "순위 업종" 관련 컬럼과 카드론 관련 컬럼은 결측이 많습니다.

6) 아무튼

데이터 구조를 보니, 고객 1명이 한 행이고 ID로 테이블을 붙일 수 있다.

그다음 Segment 분포를 보니 E가 압도적으로 많다.

고객 특성을 보니 Segment별 연령/성별/카드 수 차이가 있다.

소비 행동을 보니 A/B/C/D/E의 사용금액과 청구금액 차이가 크다.
 월별로 봐도 그 차이가 어느 정도 유지된다.
 마지막으로 결측치가 많은 컬럼도 확인했다.

EDA	실제 결과
소비/신용 행동	A/B는 카드 이용건수, 이용금액, 청구금액이 높고 E는 매우 낮음
월별 변화	이 차이가 201807~201812 6개월 동안 계속 유지됨
결측치	연체일자_B0M, 승인매출정보의 순위 업종/카드론 관련 컬럼에 결측이 매우 많음

따라서 이 EDA에서 얻은 핵심은:

Segment는 소비/신용 행동 차이와 강하게 연결되어 보입니다. A/B는 활동성이 높은 고객군, E는 활동성이 낮은 고객군처럼 보입니다. 그리고 모델링 전에 결측치가 많은 컬럼들을 따로 처리해야 합니다.

▼ 전체 결론

EDA 전체 결론

이번 EDA에서는 데이터 구조를 확인한 뒤, 2018년 12월 train 데이터를 중심으로 Segment 분포, 고객 기본 특성, 소비/신용 행동, 월별 변화, 결측치를 확인하였다.

1. 타깃 분포 확인 결과

먼저 예측해야 하는 정답값인 **Segment** 의 분포를 확인하였다. 전체 train 고객 400,000명 중 Segment E가 320,342명으로 전체의 80.09%를 차지하였다. 반면 Segment A는 162명, B는 24명에 불과했다. C는 21,265명으로 5.32%, D는 58,207명으로 14.55%였다.

즉, 이 데이터는 Segment E에 고객이 매우 많이 몰려 있는 불균형 데이터이다. 모델링 시 단순히 E를 많이 맞추는 것만으로 성능이 좋아 보일 수 있으므로, A/B/C/D처럼 고객 수가 적은 Segment를 얼마나 잘 구분하는지도 함께 확인해야 한다.

2. 기본 고객 특성 EDA 결과

기본 고객 특성에서는 Segment별 연령, 성별, 연체율, 마케팅동의율, 평균 유효 신용카드 수를 확인하였다.

연령 분포를 보면 Segment A는 40대 37.04%, 50대 38.89%로 40~50대 비중이 매우 높았다. Segment C와 D도 30~40대 비중이 높았고, Segment E는 20대 비중이 8.42%로 다른 Segment보다 상대적으로 높았다. 다만 E 역시 40대 29.58%, 50대 23.17%로 중장년층 비중도 적지 않았다.

성별 비율에서는 Segment A가 성별코드 1 비중 70.99%로 특정 성별 쪽으로 많이 치우쳐 있었다. 반면 Segment E는 성별코드 1이 50.88%, 성별코드 2가 49.12%로 거의 반반에 가까웠다.

연체율은 B가 4.17%로 가장 높았지만, B는 고객 수가 24명뿐이므로 해석에 주의가 필요하다. C는 2.22%, D는 2.49%, E는 1.46%, A는 1.23%였다.

마케팅동의율은 B가 87.50%로 가장 높고, E가 81.83%로 그다음이었다. C는 75.47%, A는 75.31%, D는 77.72%였다. B는 표본 수가 너무 작기 때문에 실질적으로는 E의 마케팅동의율이 상대적으로 높게 나타난 점이 눈에 띈다.

평균 유효 신용카드 수는 Segment A가 2.1790장으로 가장 많고, E가 1.1461장으로 가장 적었다. C는 1.8335장, B는 1.8750장, D는 1.5479장이었다. 즉, A 쪽 고객은 보유 신용카드 수가 많고, E 쪽 고객은 보유 신용카드 수가 적은 편이다.

따라서 기본 고객 특성에서는 연령, 성별, 보유 카드 수가 Segment별로 차이를 보였으며, 특히 평균 유효 신용카드 수는 Segment 구분에 도움이 될 가능성이 있다.

3. 소비 / 신용 행동 EDA 결과

소비 및 신용 행동에서는 Segment별 카드이용한도금액, 신용 이용건수, 일시불 이용금액, 청구금액, 일시불 잔액, 혜택수혜율의 중앙값을 확인하였다.

Segment A는 카드이용한도금액 중앙값이 200,964.5로 가장 높았고, 신용 이용건수도 62.0으로 가장 높았다. 일시불 이용금액은 22,571.0, 청구금액은 44,690.5, 일시불 잔액은 18,443.0이었다.

Segment B도 신용 이용건수 57.5, 일시불 이용금액 20,339.5, 청구금액 41,744.5로 높게 나타났다. 다만 B는 고객 수가 매우 적기 때문에 일반화에는 주의가 필요하다.

Segment C는 신용 이용건수 35.0, 일시불 이용금액 11,226.0, 청구금액 17,345.0으로 A/B보다는 낮지만 D/E보다는 높은 중간 수준이었다. Segment D는 신용 이용건수 24.0, 일시불 이용금액 6,385.0, 청구금액 8,528.0이었다.

Segment E는 카드이용한도금액 40,478.0, 신용 이용건수 3.0, 일시불 이용금액 1,307.0, 청구금액 1,373.0, 일시불 잔액 732.0으로 대부분의 소비/신용 지표가 가장 낮았다. 혜택수혜율도 E는 0.58로 A 1.57, B 1.53, C 1.47, D 1.52보다 낮았다.

따라서 소비/신용 행동에서는 Segment 간 차이가 매우 뚜렷하게 나타났다. A/B는 카드 사용량, 이용금액, 청구금액이 높은 고활동 고객군에 가깝고, E는 카드 사용량과 금액이 매우 낮은 저활동 고객군에 가깝다.

4. 월별 변화 EDA 결과

월별 변화에서는 2018년 7월부터 12월까지 6개월 동안 Segment별 신용 이용건수, 일시불 이용금액, 청구금액의 중앙값이 어떻게 변하는지 확인하였다.

신용 이용건수는 A가 201807에 60.0, 201812에 62.0으로 6개월 내내 약 59~62 수준을 유지했다. B도 201807에 64.5, 201812에 57.5로 높은 수준이었다. C는 35~37 수준, D는 24~27 수준이었다. 반면 E는 201807에 5.0, 201812에 3.0으로 6개월 내내 매우 낮았다.

일시불 이용금액도 비슷한 패턴을 보였다. A는 201807에 22,651.0, 201812에 22,571.0으로 약 22,000대 수준을 유지했다. B도 대부분 20,000~22,000대였다. C는 약 11,000대, D는 약 6,000대, E는 약 1,300~1,500대였다.

청구금액 역시 A/B가 높고 E가 낮았다. A는 6개월 동안 약 44,000~45,000대였고, B는 약 39,000~46,000대였다. C는 약 17,000대, D는 약 8,000~9,000대, E는 약 1,300~1,400대였다.

즉, 소비/신용 행동 차이는 2018년 12월 한 달만의 우연한 결과가 아니라, 2018년 7월부터 12월까지 6개월 동안 반복적으로 유지되는 Segment 특성으로 보인다. A/B는 지속적으로 활동성이 높고, E는 지속적으로 활동성이 낮다.

5. 결측치 EDA 결과

결측치 EDA에서는 2018년 12월 train 기준으로 1~8번 테이블의 결측 비율이 높은 컬럼을 확인하였다.

가장 결측이 심한 컬럼은 5.잔액정보의 연체일자_BOM으로, 결측 비율이 0.9990이었다. 이는 약 99.90%가 비어 있다는 뜻이다. train 고객 수가 400,000명이므로 대략 399,600명 정도는 해당 값이 비어 있는 셈이다.

그다음으로는 3.승인매출정보의 순위 업종 관련 컬럼에서 결측이 많이 나타났다. 3순위여유업종은 0.9974, 2순위여유업종은 0.9846, 3순위납부업종은 0.9638, 1순위여유업종은 0.8961, 3순위교통업종은 0.8629, 2순위납부업종은 0.8539의 결측 비율을 보였다.

또한 카드론 관련 컬럼인 최종카드론_대출일자 는 0.8285, 최종카드론_신청경로코드 는 0.8155, 최종카드론_금융상환방식코드 는 0.8154로 결측 비율이 높았다. 2.신용정보의 RV신청일자 도 0.8141로 결측이 많았다.

따라서 모델링 전에 결측치가 많은 컬럼을 그대로 사용할지, 제거할지, 또는 결측 여부 자체를 새로운 변수로 만들지 판단해야 한다. 특히 연체일자_BOM 처럼 거의 대부분 비어 있는 컬럼은 단순 수치형 변수로 쓰기 어렵지만, “연체일자가 존재하는지 여부”처럼 바꾸면 의미 있는 정보가 될 수도 있다.

최종 종합 결론

전체 EDA 결과를 종합하면, 이 데이터의 Segment는 고객의 소비/신용 행동과 강하게 연결되어 있는 것으로 보인다.

Segment E는 전체 고객의 80.09%를 차지하는 압도적인 다수 클래스이지만, 소비/신용 행동은 가장 낮은 편이다. E는 신용 이용건수 중앙값이 3.0, 일시불 이용금액 중앙값이 1,307.0, 청구금액 중앙값이 1,373.0으로 매우 낮다. 즉, E는 고객 수는 많지만 카드 활동성은 낮은 고객군으로 볼 수 있다.

반면 Segment A는 고객 수가 162명으로 매우 적지만, 카드이용한도금액 200,964.5, 신용 이용건수 62.0, 일시불 이용금액 22,571.0, 청구금액 44,690.5로 소비/신용 활동성이 가장 높은 고객군이다. A는 40~50대 비중도 높고, 평균 유효 신용 카드 수도 2.1790장으로 가장 많다.

Segment C와 D는 A/B와 E 사이의 중간 단계처럼 보인다. C는 이용건수 35.0, 일시불 이용금액 11,226.0, 청구금액 17,345.0이고, D는 이용건수 24.0, 일시불 이용금액 6,385.0, 청구금액 8,528.0이다. 즉, 소비 수준이 A/B > C > D > E 순서로 낮아지는 흐름이 나타난다.

월별 변화에서도 이 차이는 201807~201812 기간 동안 지속적으로 유지되었다. 따라서 Segment별 소비/신용 차이는 특정 월의 우연한 현상이 아니라, 고객군별로 반복적으로 나타나는 구조적인 차이로 해석할 수 있다.

다만 데이터에는 두 가지 주의점이 있다. 첫째, Segment 분포가 매우 불균형하다. E가 80.09%이고 A/B는 매우 적기 때문에, 모델 평가 시 전체 정확도만 보면 안 된다. 둘째, 일부 컬럼은 결측 비율이 매우 높다. 특히 연체일자_BOM, 승인매출정보의

순위 업종 컬럼, 카드론 관련 컬럼은 결측 처리가 필요하다.

결론적으로, 이 데이터는 Segment별로 고객의 카드 사용량, 이용금액, 청구금액, 카드 보유 수가 뚜렷하게 다른 데이터이다. 따라서 모델링에서는 소비/신용 행동 변수들이 Segment 예측에 중요한 역할을 할 가능성이 높다. 동시에 타깃 불균형과 결측치 문제를 반드시 처리해야 한다.